

# Sieci neuronowe

Przewidywanie poziomu dochodów na podstawie danych demograficznych

- **Autorzy:** Mateusz Hypta 280116, Mateusz Kwapisz 280107
- **Technologie:** Python, TensorFlow/Keras, Scikit-learn

# Cel projektu i zbiór danych

Co chcemy osiągnąć?

**Problem:** Klasyfikacja, czy dana osoba zarabia powyżej 50 tys. USD rocznie ( $>50K$ ) czy poniżej ( $\leq 50K$ ).

**Dane:** Zbiór "Adult" zawierający ~32 tys rekordów.

**Cechy:**

- Demograficzne: wiek, rasa, płeć.
- Społeczne: edukacja, stan cywilny, relacje rodzinne.
- Zawodowe: profesja, branża, liczba godzin pracy tygodniowo.

# Wyzwanie: Niebalansowane klasy

## Problem "Class Imbalance"

### Wyzwanie: Niebalansowane klasy

- **Dystrybucja danych:** Osoby zarabiające  $\leq 50K$  stanowią ok. **76%** populacji, a  $> 50K$  jedynie **24%**.
- **Zagrożenie:** Model może wpaść w pułapkę „Leniwego Klasyfikatora” – osiągnąć wysoką dokładność (**Accuracy  $\approx 76\%$** ) poprzez samo przypisywanie klasy większościowej, całkowicie ignorując mniejszość.

### Zastosowane rozwiązanie: Random Oversampling

- **Zasada:** Technika zastosowana **wyłącznie na danych treningowych**, aby zapobiec faworyzowaniu większości przez sieć.
- **Mechanizm:** Losowe powielanie przykładów klasy mniejszościowej ( $> 50K$ ) do momentu osiągnięcia proporcji **1:1**.
- **Liczliwość (Trening):**
  - Przed: ok. 22 600 vs ok. 7 500 ( $> 50K$ ).
  - Po: ok. 22 600 vs 22 600 ( $> 50K$ ).
- **Efekt:** Model widzi oba scenariusze z taką samą częstotliwością, co wymusza na sieci naukę realnych różnic demograficznych zamiast zgadywania

# Architektura Sieci Neuronowej

## Budowa modelu (MLP, 2 warstwy ukryte)

**64 neurony:** Wystarczająco dużo, by zrozumieć wszystkie cechy wejściowe, ale nie za dużo, by nie "zapchać" pamięci.

**32 neurony:** Kondensuje wiedzę – odrzuca szum, zostawia tylko fakty decydujące o zarobkach.

**Dropout (0.3 - 0.4):** Klucz do sukcesu. Bez niego model uczy się danych na pamięć (overfitting) i zawodzi w rzeczywistości.

Parametr	Najlepsza Wartość	Dlaczego ta wygrała?
Architektura	[64, 32]	Najlepszy balans między precyzją a szybkością.
Dropout	0.3	Wyższy dropout lepiej chroni przed błędami na nowych danych.
Learning Rate	0.0005	Standardowa szybkość "Adam", która trafia w optimum.
Metryka AUC	~0.92	Oznacza, że model dobrze oddziela obie grupy.


# Metodologia: Eksperyment 300 prób

## Optymalizacja poprzez iterację

### Optymalizacja poprzez iterację

- **Losowość startowa:** Sieci neuronowe rozpoczynają proces uczenia z losowymi wagami (inicjalizacja wag). Różny „punkt startu” sprawia, że każda próba może prowadzić do nieco innego wyniku końcowego.
- **Szukanie optimum:** Przeprowadzenie łącznie **300 treningów** (12 kombinacji  $\times$  25 powtórzeń każdej) pozwala uniknąć „pułapek” w postaci minimów lokalnych i precyzyjnie wyłonić najlepszą architekturę.
- **Statystyczna pewność:** Wybieramy model, którego wysoka skuteczność (AUC =0.9211) nie jest dziełem przypadku, lecz stabilnym wynikiem udowodnionym wielokrotnym testem, co eliminuje wpływ losowej inicjalizacji.

# Analiza Wyników



Skuteczność najlepszego modelu

		Macierz Pomylek (Confusion Matrix)	
		<=50K	>50K
Prawdziwa klasa	<=50K	1217	238
	>50K	215	1240

**Accuracy:** ~85% (ogólna poprawność).

## Precyzja vs Recall:

- Model świetnie radzi sobie z klasą <=50K.
- Dzięki wagom/oversamplingowi, **Recall dla klasy >50K** (wykrywalność bogatszych osób) wzrósł do wysokiego poziomu (~65%).
- Precyzja dla klasy >50K: **~76%**

**Krzywa ROC-AUC:** Wysoka wartość pola pod krzywą świadczy o dobrej separacji klas przez model.

# Wnioski i praktyczne zastosowanie

## Główne Wnioski

- **Skuteczność modelu:** Uzyskana ogólna dokładność (**Accuracy**) na poziomie **84.43%** oraz bardzo wysoki współczynnik **AUC (0.9211)** potwierdzają, że sieci neuronowe MLP doskonale radzą sobie z nieliniowymi zależnościami w danych demograficznych.
- **Klucz do sukcesu – Balans:** Dzięki technice **Oversampling** wyeliminowano ryzyko „Leniwego Klasyfikatora”, który ignorowałby mniejszość. Model zyskał realną zdolność wykrywania wysokich dochodów, osiągając **Recall** na poziomie **85.22%**.
- **Stabilność i Precyzja:** Proces optymalizacji (**300 treningów**) pozwolił na uzyskanie wysokiej precyzji (**83.90%**) dla klasy >50K. Model wykazuje unikalną symetrię błędów (**238 Fałszywie Pozytywnych** vs **215 Fałszywie Negatywnych**), co udowadnia, że nie faworyzuje on żadnej z grup.